Grupo A: Limitaciones

Public, no Private. Medimos sobre el Public de Kaggle, una parte de los clientes de un solo mes, con el máximo de 6 cortes. El Private recién se conoce el 15 de noviembre, después del video.

Cambio de métrica. El diseño decía promedio de los cortes; la cátedra aclaró después que en Kaggle la ganancia de una corrida es el máximo del Public. Reportamos el máximo y dejamos el promedio como chequeo: las dos dan el mismo ganador.

No hay una línea base sin pandemia. En el dataset gerencial, «todos los meses» empieza en 202005, es decir, en plena pandemia. El experimento compara cuánta pandemia dejar, no pandemia contra prepandemia.

Menos datos y menos pandemia van juntos. V3 entrena con el 29 % de las filas y el 39 % de las bajas de V0; el experimento no separa los dos efectos.

Los primeros meses de V0 están incompletos. El dataset gerencial arranca en 202005: ese mes no tiene lags y 202006 no tiene el de orden 2, y además 202006 tiene 12 variables catastróficas en NA. V0 es la única variante que entrena con esos meses, así que parte de su menor ganancia puede deberse a la calidad de los datos y no a la pandemia.

V1 no es del todo sin pandemia. Los lags de noviembre y diciembre de 2020 todavía miran meses del ASPO. Ese efecto lo estudia el Problema #05.

Grupo A: Limitaciones (continuación)

La validación es un único mes. El grid search y el early stopping se deciden solo con el AUC de 202107. Si julio no representa bien a septiembre, los hiperparámetros elegidos pueden no ser los óptimos.

Cortes del notebook. La curva media de V0 todavía sube en 1.300 envíos y la de V1 es más alta en 800, así que sus máximos pueden estar algo subestimados: el máximo de la corrida cae en el primer o el último corte en 5 de 10 semillas en V0, 5 en V1, 4 en V2 y 2 en V3.

Grilla del baseline. El grid search eligió min_data_in_leaf = 64, el borde de la grilla, en 20 de nuestras 40 corridas, y num_leaves = 512 en 8. No la ampliamos para no tocar el workflow; con una grilla más amplia las ganancias podrían ser otras.

Alcance. Con 10 semillas el p mínimo del Wilcoxon es 0,002, y con este ruido no se distinguen diferencias menores a unos 3 puntos, como la de V2 contra V3. El corte del ASPO es el del AMBA y no sabemos dónde viven los clientes. Los resultados del Grupo B, sobre julio de 2021, se comparan con estos solo en conclusiones, no en ganancia.

Grupo A: Resultados: ganancia por semilla y variante

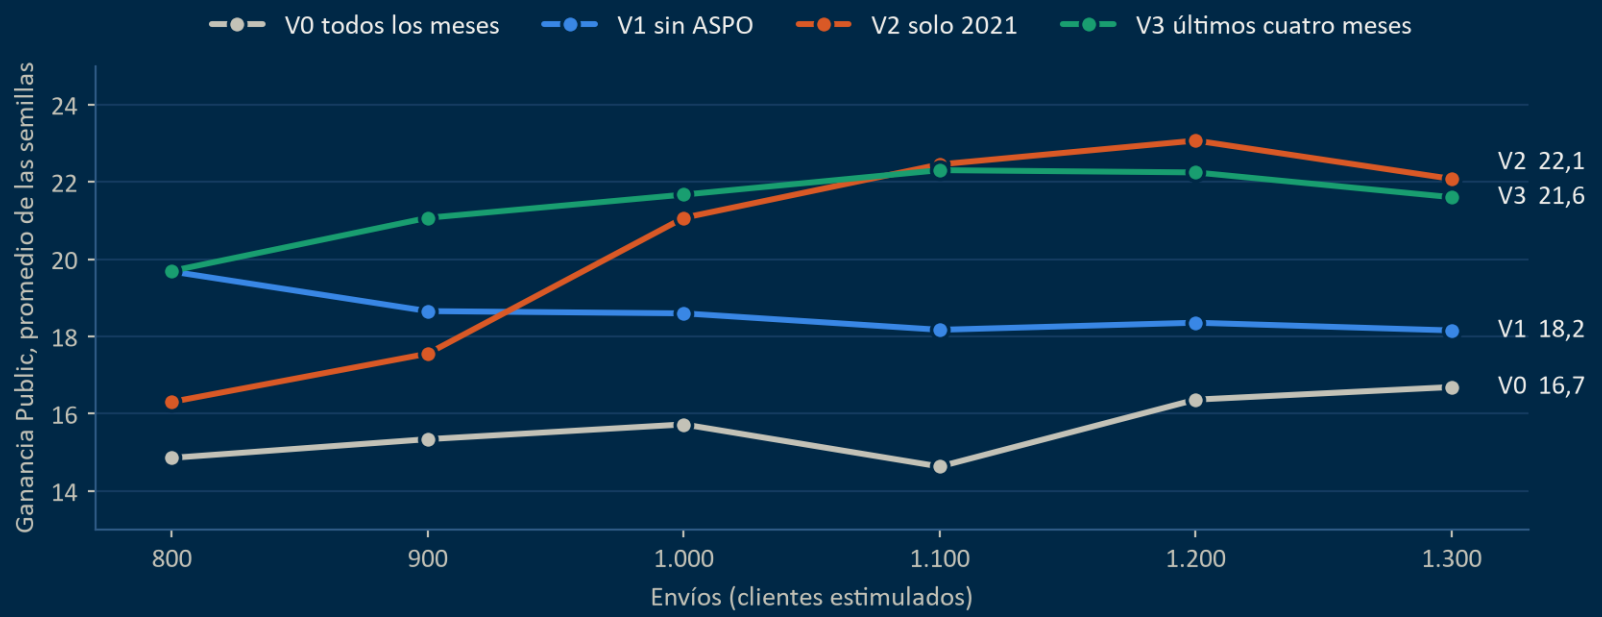
Ganancia de cada corrida = máximo Public de los 6 cortes (800 a 1.300 envíos). Mismas semillas en las cuatro variantes.

Semilla	V0 todos los meses	V1 sin ASPO	V2 solo 2021	V3 últimos cuatro meses
150001	19,1	22,3	20,1	**27,6**
222247	17,6	**21,3**	20,7	20,4
199999	20,7	23,9	**28,8**	24,9
777781	23,3	21,4	20,8	**28,1**
999983	20,5	24,2	**25,1**	24,4
101929	19,4	17,6	29,0	**30,8**
232327	19,8	22,5	**25,0**	22,4
456791	18,2	20,2	**20,7**	19,4
454451	16,7	22,8	**31,4**	26,1
123457	24,3	19,9	23,5	**26,2**
Promedio	**20,0**	**21,6**	**24,5**	**25,0**
Desvío entre semillas	2,4	2,0	4,1	3,5

En amarillo, la mejor variante de cada semilla. Diferencia promedio contra V0 y semillas en que el recorte supera a V0: V1 +1,7 (7 de 10), V2 +4,5 (8 de 10), V3 +5,1 (10 de 10).

Grupo A: Resultados: curva de ganancia por corte

Promedio de las semillas en cada uno de los 6 cortes, una curva por variante.

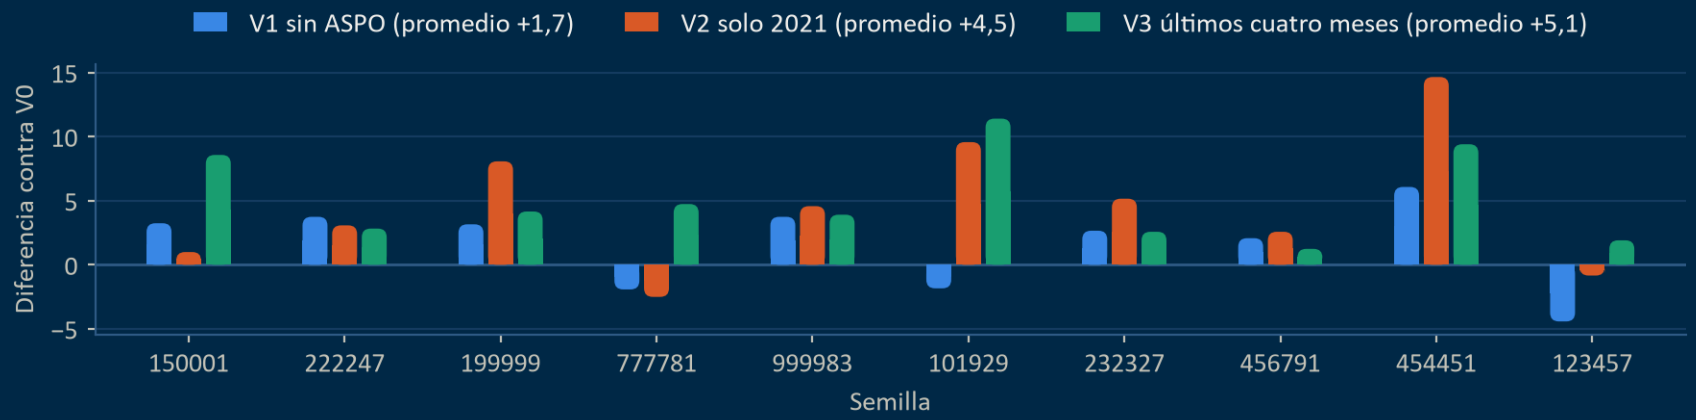


Cada punto es el promedio de las 10 semillas en ese corte.

Los tres recortes quedan por encima de V0 en los 6 cortes.

Grupo A: Resultados: comparación con V0 por semilla

Diferencia de cada recorte contra V0 con la misma semilla.



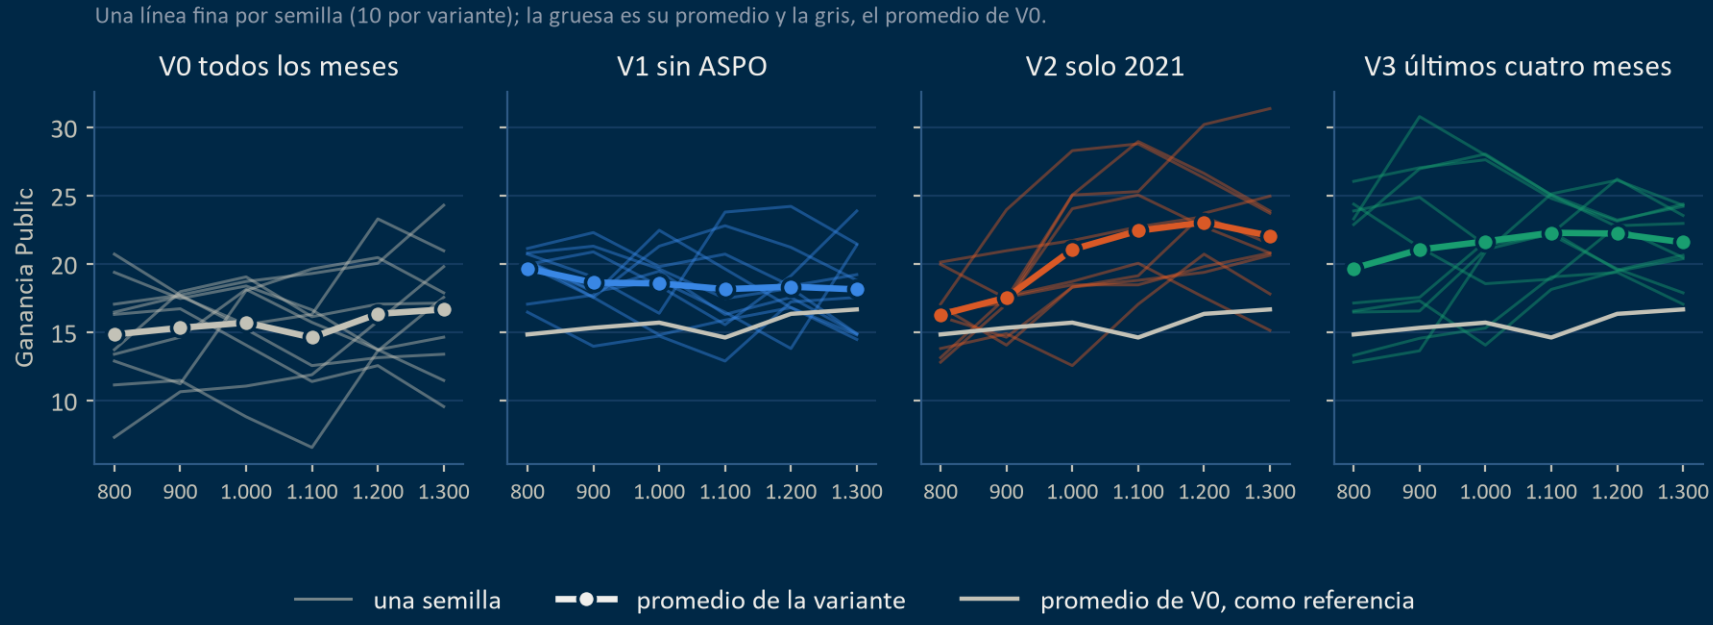
Una barra por semilla y recorte: ganancia del recorte menos la de V0 con la misma semilla.

Comparación con V0	Diferencia media	Semillas que superan a V0	p Wilcoxon	Veredicto
V1 sin ASPO	+1,66	7 de 10	0,1309	no gana
V2 solo 2021	+4,54	8 de 10	0,0137	**gana**
V3 últimos cuatro meses	+5,08	10 de 10	0,0020	**gana**

Test de Wilcoxon de rangos con signo, exacto, a dos colas. Regla fijada de antemano: $p < 0,05$ a favor del recorte.

Grupo A: Resultados: dispersión entre semillas

Cada panel: las 10 corridas de una variante (líneas finas), su promedio (línea gruesa) y el promedio de V0 como referencia (gris).



Máximo del promedio de cada variante: V1 en 800 envíos, V3 en 1.100, V2 en 1.200 y V0 en 1.300.

Grupo A: Resultados: todas las comparaciones

Las 6 comparaciones pareadas entre las 4 variantes, con corrección de Holm (pairwise.wilcox.test); V0 es una variante más.

Comparación	Diferencia media	Gana en	p Wilcoxon	p corregido (Holm)
V1 contra V0	+1,66	7 de 10	0,1309	0,2617
V2 contra V0	+4,54	8 de 10	0,0137	0,0684
V3 contra V0	**+5,08**	**10 de 10**	**0,0020**	**0,0117**
V2 contra V1	+2,88	7 de 10	0,0840	0,2520
V3 contra V1	+3,42	7 de 10	0,0488	0,1953
V3 contra V2	+0,54	4 de 10	0,9219	0,9219

Ganancia de cada corrida = máximo Public de los 6 cortes. Test de Wilcoxon de rangos con signo, exacto, a dos colas. En amarillo, las que quedan por debajo de 0,05 con Holm: V3 contra V0 (0,0117).

Grupo A: Resultados: chequeo con la métrica original

La misma comparación contra V0 con las dos métricas: máximo Public de los 6 cortes (la de la cátedra) y promedio Public de los 6 cortes (la del diseño).

Comparación con V0	Máximo: diferencia	gana en	p	Promedio: diferencia	gana en	p
V1 sin ASPO	+1,66	7 de 10	0,1309	+3,00	7 de 10	**0,0273**
V2 solo 2021	+4,54	8 de 10	**0,0137**	+4,82	9 de 10	**0,0039**
V3 últimos cuatro meses	+5,08	10 de 10	**0,0020**	+5,83	10 de 10	**0,0020**

Las dos métricas dan el mismo orden y el mismo mejor recorte. Pasan la regla ($p < 0,05$, en amarillo): con el máximo V2, V3; con el promedio V1, V2, V3.

Las ganancias medias por variante con el promedio: V0 15,6, V1 18,6, V2 20,4, V3 21,4.

Grupo A: Discusión

Los tres recortes dieron más ganancia que entrenar con todos los meses, y la mejora crece a medida que el entrenamiento se acerca a septiembre: 21,6 sin ASPO, 24,5 solo 2021 y 25,0 con los últimos cuatro meses, contra 20,0 de la línea base. V3 ganó en las 10 semillas (p 0,002) y es la única diferencia que sobrevive a la corrección de Holm; V2 y V3 no se distinguen entre sí (p 0,92).

La primera parte de la hipótesis se sostiene y la segunda no. Pensábamos que cuatro meses eran pocos datos, pero V3 entrena con el 29 % de las filas y el 39 % de las bajas de V0 y aun así es la mejor. En este dataset, parecerse al mes que se predice pesa más que la cantidad de datos: durante el ASPO se iban 44 clientes por mes y en 2021, 80. «Más meses siempre es mejor» vale cuando los meses son del mismo régimen.

Sacar solo el ASPO rinde poco: +1,7, 7 de 10 semillas, sin significación. Una explicación es que los lags de noviembre y diciembre de 2020 todavía miran meses del ASPO. Y el AUC de validación en julio va al revés de la ganancia (0,954 para V0 contra 0,949 para V3): ordenar bien julio no garantiza ganar en septiembre, por eso la comparación se hace solo por ganancia.

El resultado es sobre el Public de un solo mes y con el máximo de 6 cortes; el Private del 15 de noviembre es la prueba de fuego. La curva de V0 todavía sube en 1.300 envíos, así que su máximo puede estar algo subestimado, pero con 5 puntos de diferencia y 10 de 10 semillas es difícil que eso dé vuelta el resultado.

Con otros problemas: el Grupo B del Problema #01 no encontró diferencia significativa al reparar las variables rotas de junio de 2020 (interpolar +0,96, p 0,195), y con esta receta ese mes queda afuera, así que esa decisión deja de importar. En el Problema #08, con otro dataset, sacarle a la búsqueda meses recientes para validar en más meses no mejoró (3 meses: −3,44, p 0,11): va en el mismo sentido, pero sin significación.

Grupo A: Conclusiones

Qué conviene. Para predecir septiembre de 2021 con el dataset gerencial, conviene no entrenar con los meses de 2020. Entrenar desde marzo de 2021 dio 25,0 de ganancia Public contra 20,0 de la línea base y ganó en las 10 semillas (p 0,002); desde enero de 2021 quedó casi igual (24,5, 8 de 10 semillas). Sacar solo el ASPO no alcanza (21,6, 7 de 10, p 0,13).

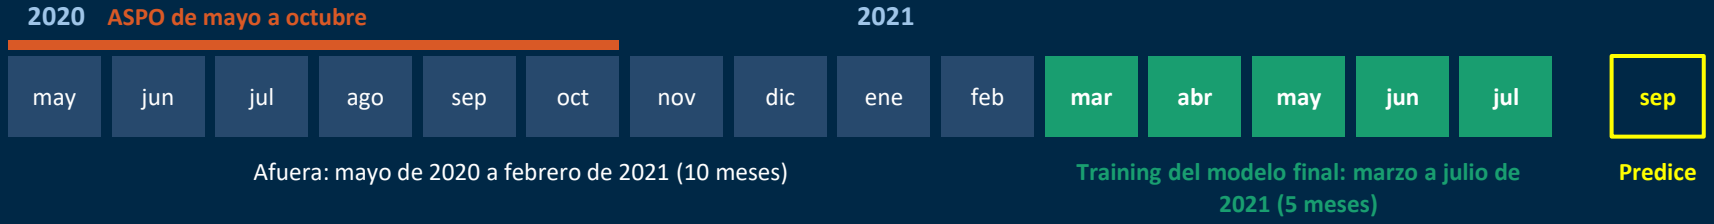
Qué pasó con la hipótesis. Acertó en el sentido y falló en el límite: más datos no fue mejor cuando esos datos son de otro régimen. El efecto es grande frente al ruido entre semillas: una diferencia media de 5,1 con un desvío de 3,5.

Qué no sabemos. Si vale para otros meses y para el Private. Con el promedio de los cortes, la métrica original del diseño, el orden es el mismo y los tres recortes pasan la regla.

Grupo B. Prueba otra palanca: bajarles el peso a esos meses en vez de sacarlos, evaluando en julio de 2021 sin Kaggle. Sus ganancias no se comparan con las nuestras. Si llega a lo mismo, la conclusión se refuerza; si no, el efecto depende del mes que se predice o de la forma de recortar.

Grupo A: Recomendación concreta

Para la predicción final gerencial con la z719: **entrenar solo desde marzo de 2021**: training del grid 202103 a 202106, validación 202107 y modelo final 202103 a 202107. Todo 2020 y enero y febrero de 2021 quedan afuera. El modelo final se arma con modifyList, como en el experimento; nada más cambia.



Efecto esperado: unos 5 puntos más de ganancia Public que la línea base (25,0 contra 20,0), con 10 de 10 semillas a favor y p 0,002.

Opción prudente: si se prefiere conservar más datos, entrenar desde 202101 da casi lo mismo (24,5, 8 de 10 semillas, p 0,014). Lo que no conviene es entrenar con 2020 completo ni sacar solo los meses del ASPO.

Revisión: la receta se contrasta el 15 de noviembre con el Private; si el orden cambia, vale más el Private que esto.

Grupo A: Futuros problemas y experimentos

Private. Repetir las comparaciones cuando cierre la competencia y ver si V3 sigue por encima de V2.

Separar los dos efectos. Entrenar con la misma cantidad de meses en distintas posiciones (cuatro meses de 2020 contra cuatro de 2021) y probar pesos decrecientes por antigüedad en vez de cortar.

Ventanas mes a mes. Primer mes de training entre noviembre de 2020 y abril de 2021, con más semillas, para ubicar dónde empieza a ganar el recorte y dónde empieza a perder: con 10 semillas, V2 y V3 no se distinguen.

Grilla. Ampliarla cuando el óptimo cae en el borde (min_data_in_leaf por debajo de 64, num_leaves por encima de 512) y repetir el experimento con la grilla nueva.

Validación en varios meses. Elegir el primer mes de training validando sobre varios meses con clase conocida o con walk forward validation, en lugar de un solo mes, en la línea de los Problemas #08 y #10.

Dataset de los analistas y Problema #05. El mismo experimento con el dataset que tiene meses previos a la pandemia, para probar «sin pandemia» de verdad y no solo «sin ASPO». Y combinarlo con el #05: limpiar los lags que miran meses del ASPO en vez de sacar los meses.

Grupo A: Anexo

Repositorio: github.com/Facundolondero/ExpColaborativo07_GrupoA. Scripts de las corridas (R en una PC y notebook de Colab), de las subidas a Kaggle y del análisis; los puntajes Public de los 240 envíos de los dos integrantes; tablas, gráficos y tests; y de cada corrida PARAM.yml, el grid search completo y la importancia de variables.

Cómo replicar: R con data.table, lightgbm, yaml y R.utils; Rscript exp07_batch.R full A corre las 40 corridas y descarga el dataset si falta; exp07_subir.py --subir sube los 6 cortes de cada corrida; exp07_bajar_puntajes.py y exp07_resultados.py arman las tablas y los tests. En Colab, subir el notebook con el entorno en R y correr en orden.

Datos y semillas: gerencial_competencia_2026.csv.gz, meses 202005 a 202107 con clase, future 202109. Semillas 150001, 222247, 199999, 777781 y 999983 (Facundo); 101929, 232327, 456791, 454451 y 123457 (Francisco).

Variante	Primer mes	Meses	Filas de training	BAJA+2	AUC validación	Iteraciones
V0 todos los meses	202005	14	179.449	853	0,954	470
V1 sin ASPO	202011	8	104.483	587	0,952	292
V2 solo 2021	202101	6	78.630	472	0,952	545
V3 últimos cuatro meses	202103	4	52.606	333	0,949	500

Meses, filas y BAJA+2 del training (hasta 202106). AUC medio de validación en 202107; no se usa para comparar variantes. Iteraciones: mediana del modelo final, elegidas por early stopping (200) sobre un tope de 2.048.