Grupo A: Hipótesis Experimental del Problema #7

El workflow de la cátedra entrena con todos los meses del dataset gerencial, de mayo 2020 a junio 2021, incluidos los seis meses del ASPO. En esos meses los clientes operaban distinto y se iban menos: 44 bajas por mes durante el ASPO contra 80 por mes en 2021.

Entrenar sin los meses del ASPO da más ganancia al predecir septiembre de 2021, porque el modelo aprende de un período más parecido al que predice.

Pero sacar meses también es sacar datos, así que recortar demasiado (solo los últimos cuatro meses) debería perjudicar.

Grupo A: Revisión de Bibliografía

Gama et al. (2014). A survey on concept drift adaptation. ACM Computing Surveys 46(4).
https://doi.org/10.1145/2523813

Lu et al. (2018). Learning under concept drift: a review. IEEE TKDE 31(12).
https://arxiv.org/abs/2004.05785

Scholz y Klinkenberg (2007). Boosting classifiers for drifting concepts. Intelligent Data Analysis 11(1).
https://doi.org/10.3233/IDA-2007-11102

BCRA (2020). Informe de Inclusión Financiera, noviembre 2020.
https://www.bcra.gob.ar/archivos/Pdfs/PublicacionesEstadisticas/IIF_0220.pdf

Decretos 297/2020 (ASPO) y 875/2020 (el AMBA pasa a DISPO el 9 de noviembre de 2020).
argentina.gob.ar/normativa

Heaven (2020). Our weird behavior during the pandemic is messing with AI models. MIT Technology Review.
https://www.technologyreview.com/2020/05/11/1001563/

Demšar (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research 7.
https://www.jmlr.org/papers/v7/demsar06a.html

Denicolay (2026). Libro de la asignatura, secciones 5.3 (el mejor Public casi nunca es el mejor Private) y 6.16 (entrenar con la mayor cantidad de meses, «quizás con salvedades pandémicas»).

Grupo A: Sesgos Cognitivos (conflictos de intereses)

Viví el ASPO y trabajo con encuestas: para mí 2020 es un año aparte, y antes de ver un número ya creía que sacar esos meses iba a mejorar el modelo. Además fui yo quien eligió el corte en noviembre de 2020, y me convendría que sea el bueno.

En contra de mi creencia juega lo que vi en la Tarea Hogar 04: cambiar solo la semilla mueve mucho el Public, y con 90 bajas por mes las diferencias entre variantes pueden quedar escondidas en el ruido. Por eso fijé la regla de decisión antes de ver los resultados.

Grupo A: Diseño experimental

Se corre el workflow z610 de la cátedra tal cual y lo único que varía es el primer mes de entrenamiento. Validación en 202107, entrenamiento final hasta 202107 y predicción de 202109.

Variante	Primer mes	Meses de training	Meses del entrenamiento final
V0 todos los meses (línea base)	202005	14	15
V1 sin ASPO	202011	8	9
V2 solo 2021	202101	6	7
V3 últimos cuatro meses	202103	4	5

Cada variante se corre con las mismas 10 semillas y en cada corrida se vuelve a hacer el grid search completo de hiperparámetros. Por corrida se suben a Kaggle 15 cortes, de 600 a 1.300 envíos, y se mide el promedio de la curva de ganancia y no el mejor corte, porque el mejor Public casi nunca es el mejor Private (libro, 5.3).

Cada recorte se compara con V0 de a pares por semilla, con el test de Wilcoxon. La regla quedó fijada antes de ver resultados: una variante es mejor si gana en al menos 8 de las 10 semillas con $p < 0,05$.

Dos cambios al notebook, iguales en las cuatro variantes: el entrenamiento final usa modifyList, porque con c(fijos, mejores) LightGBM ignora lo que eligió el grid search, y a los cortes del notebook (800 a 1.300) se suman 600, 650, 700 y 750.

Grupo A: Limitaciones

Se mide sobre el Public de Kaggle, que es una parte de los clientes de septiembre, y sobre un solo mes.

Sacar meses mezcla dos efectos: menos datos y menos pandemia. V2 y V3 siguen recortando después del ASPO, así que si ahí la ganancia cae, pesa más la pérdida de datos.

Los lags de noviembre y diciembre de 2020 todavía miran meses del ASPO. Ese efecto lo estudia el Problema #05.

Con 10 semillas y 90 bajas por mes, una diferencia chica puede no detectarse.

El corte del ASPO es el del AMBA, y no sabemos dónde viven los clientes del banco.